Artificial Intelligence Capstone Project I

Dataset:

Initially, my plan was to focus on image classification for clothing. However, a mere two days before the deadline, I experienced a sudden change of heart. I was struck by a more innovative and compelling idea: fake news detection. In today's digital landscape, the proliferation of fake news has reached alarming levels, sowing confusion, and misinformation among the masses.

To ensure the efficacy of my project, I opted to source my dataset from <u>Politifact</u>, a highly respected fact-checking website renowned for its thorough examination of news articles and statements from public figures. Leveraging web crawler techniques, I gathered data from <u>Politifact</u>. Besides <u>Politifact</u>, I also collected data from Twitter, because Twitter is a social media that full of fake news. Alongside my classmate, 陳沂亨, we manually annotated labels for each news title (0 for fake news title and 1 for real news title). The essence of my model lies in its ability to discern the authenticity of news titles, swiftly distinguishing between genuine information and falsified reports.

I prepared 4 kinds of datasets to do experiments. They are, biased dataset (20% real news title and 80% fake news title), unbiased dataset (45% real news title and 55% fake news title), unbiased large dataset (contain approximately 2500 news title), dataset in French (Just translate large dataset into French). And I also prepare two testing datasets, one is for English, and another is for French.

Algorithms:

I use two supervised learning algorithms and one unsupervised learning algorithm to process the dataset. The two supervised learning algorithms are Support Vector Machine (SVM) and Convolutional Neural Network (CNN), and the unsupervised learning algorithm, Latent Dirichlet Allocation, and why I used these methods because SVM can handle both linear and non-linear relationships between features and labels, making it suitable for capturing complex patterns in textual data; CNNs are adept at capturing local patterns or features within data. In the context of text classification, the words in a sentence can be considered as a sequence of data. And LDA can be used to extract features from the text data that capture the underlying structure of the documents. These features can then be used as input to other machine learning models for classification tasks.

Analysis:

Supervised Learning:

o Support Vector Machine:

Accuracy: 0.80

Precision: 0.70

Recall: 0.86

F1 Score: 0.81

AUROC: 0.84

Confusion Matrix: $\begin{bmatrix} 141 & 132 \\ 23 & 43 \end{bmatrix}$

Convolutional Neural Network:

Accuracy: 0.88

Precision: 0.90

Recall : 0.817

F1 Score: 0.829

AUROC: 0.90

Confusion Matrix: $\begin{bmatrix} 161 & 97 \\ 28 & 53 \end{bmatrix}$

o Conclusion:

In conclusion, both SVM and CNN models demonstrated strong performance in classifying fake news articles, with SVM achieving an accuracy of 0.8 and CNN achieving an accuracy of 0.88. The SVM model exhibited balanced precision, recall, and F1-scores above 0.77, along with a strong AUROC score of 0.84. CNN, on the other hand, demonstrated robust performance in precision and recall, with F1-scores above 0.8 and an AUROC score of 0.9. These results indicate that both SVM and CNN are effective in distinguishing between fake and real news articles, making them valuable tools for fake news detection tasks.

Unsupervised Learning:

• Latent Dirichlet Allocation:

Accuracy: 0.687

	Precision	Recall	F1 Score	Support
0	0.8	0.82	0.81	273
1	0.16	0.14	0.15	66
Accuracy	X	X	0.69	339
Macro Avg.	0.48	0.48	0.48	339
Weighted Avg.	0.67	0.69	0.68	339

o Conclusion:

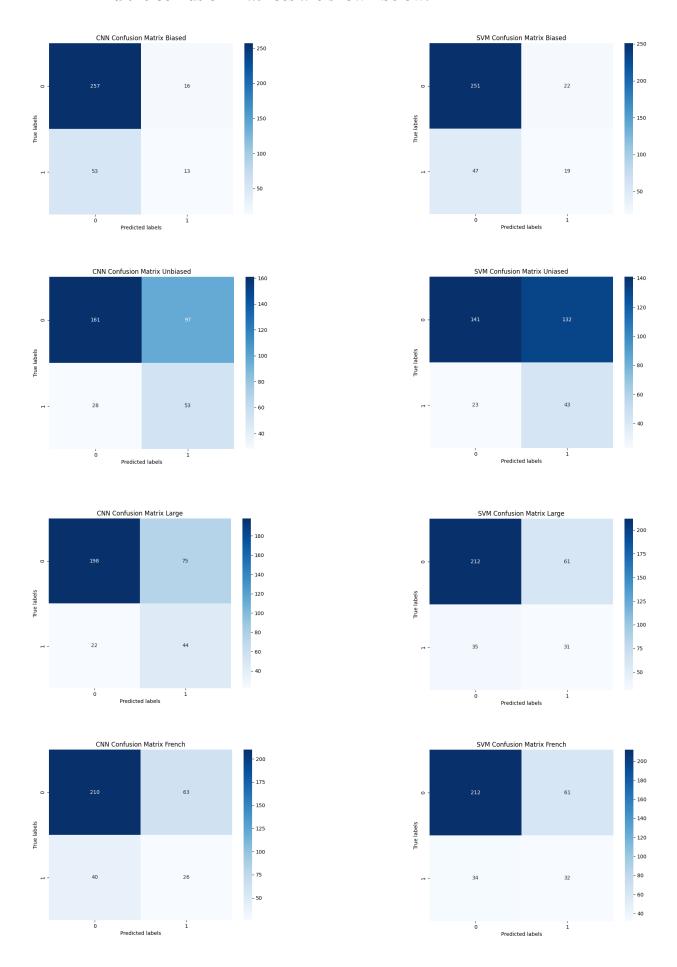
In unsupervised learning, LDA showed moderate performance in classifying fake news. While LDA achieved an accuracy of 0.687, its precision, recall, and F1-scores were comparatively lower, indicating a less precise classification compared to supervised learning approaches. The model's classification report revealed challenges in effectively identifying fake news articles, with a precision of 0.16 and a recall of 0.14 for the minority class (fake news). Overall, LDA may not be as effective as supervised learning methods like SVM and CNN for fake news detection, suggesting the importance of labeled data for training robust classification models.

Experiments:

I conducted various experiments on my dataset, which involved biased and unbiased approaches, as well as working with larger datasets and exploring different languages, and I measure it in accuracy.

	Biased	Unbiased	Large	French
CNN	0.9	0.92	0.97	0.8
SVM	0.82	0.85	0.9	0.75
LDA	0.28	0.68	0.77	0.42

And the confusion matrices are shown below.



Based on the experiments conducted on various datasets with different biases, sizes, and languages, the following insights can be derived:

- Unbiased datasets consistently outperform biased ones across all models.
- Larger datasets generally lead to better performance.
- French-language datasets tend to perform lower compared to English-language ones.
- CNN outperforms SVM and LDA across all scenarios, indicating its effectiveness in fake news detection tasks.

These observations suggest that unbiased, larger English-language datasets are preferable for training CNN-based models for fake news detection.

Discussion:

• Expectations vs. Results:

Generally aligned with expectations, especially regarding unbiased and larger datasets yielding better performance. French-language datasets performed comparatively worse, possibly due to vocabulary differences and dataset size limitations.

• Factors Affecting Performance:

Dataset characteristics, including bias, size, and language, significantly impact model performance. Biased datasets hinder generalization, while language differences affect vocabulary and linguistic nuances, influencing model accuracy.

• Experiments with More Time:

Explore advanced preprocessing techniques, additional features, advanced architectures (e.g., RNNs, transformers), ensemble learning, and domain adaptation methods, and explore different languages to identify which ones yield the best performance, considering linguistic characteristics and dataset availability.

• Learnings and Remaining Questions:

Dataset quality is critical for model performance in fake news detection. Languagespecific preprocessing is crucial. Remaining questions include investigating more sophisticated feature representations and developing interpretable models for deeper insights.

Dataset Documents:

Link to dataset: <u>Datasets</u>

Part of large dataset:

large



Part of French dataset:

French

Le Code américain indique qu'une personne reconnue cougable de traitéens exati-prise par le groupe jusqu'à l'intersection occupée la plus proche et à midi accroché au cou jusqu'à mont. Le président Joe Bilden a été-transporté d'urgence à l'hôpital de fapon institendue. Avoius avons les plus grandes classes d'agents correctionnels que nous ayons jamais ques auparavant. Les incendies de forêt du Texas pour interdire la publication de jusqu'à montre de la companie de la companie de face d'ut fexas sont une attaque délibérée contre l'approvisionnement alimentaire aux États-Unis. La pétition du Texas pour interdire la spubérésation aérosciolése- est la preuve de Chemtralis. Il y a moins de deux semaines avant la date limite pour s'inscrire pour voter dans le Wisconsis. Bifair la nouvelle application de journal d'Agen Permet à Quiconque près de chez vous connaisses votre nom complet et exactement où vous êtes géo-localisé.* Michael Moore soutient Trump lors des élections de 2024. Si vous allies «n'imports où dans le monde», vous pourriez obtenir une ordonnance remplie de 40% à 80% de moins qu'elle coûte aux États-Unis aux États-Unis Autorité de la companie	0 0 1 0 0 0 0 0
Nous avons les plus grandes classes d'agents correctionnels que nous ayons jamais eues auparavant. Les incendies de forêt du Texas sont une attaque -délibérée contre l'approvisionnement alimentaire aux États-Unis. Les incendies de forêt du Texas and tait le limite pour s'inscrirée pour voter dans le Wasconsis. La pétition du Texas pour interdire la -pulvérisation aérosolisée- est la preuve de Chemtralis. Il y a moint de deux semaines avant la date limite pour s'inscrirée pour voter dans le Wasconsis. By a moint de deux semaines avant la date limite pour s'inscrirée pour voter dans le Wasconsis. By a moint de deux semaines avant la date limite pour s'inscrirée pour voter dans le Wasconsis. Bloriée in anouvelle application de journal d'Apple "Permet à dajourque près de chez vous comaisses votre nom complet et exactement où vous êtes géo-localisé." Michael Moore soutient Trump lors des élections de 2024. Si vous alliez-nimports où dans le monde, vous pourriez obtenir une ordonnance rempile de 40% à 80% de moins qu'elle coûte aux États-Unis exactions locales, les immigrants lifejaux peuvent voters. Le comité de boxe olympique « décidé cette année que les hommes pouvaient se bloquer centre les femmes aux Jeux olympiques. C'Unick Schumer a pris le micro chaucé comploter pour -billaner les républicaires et Magas- pour des retards de réforme. Le comité de boxe olympique « a édicidé cette année que les hommes que les maisons d'une certaire couleur sont épargrées des incendies de forêt. Le ministre poionais des Affaires étranglères a édicidre que les États-Unis étaisent "dynfonctionnels et peur liables" cer 1 n' pas envoyé plus d'idé à l'Uraine. "7 a millions d'illiquex sont entrés aux États-Unis étaiser the sectement de cortir	1 0 0 0 0 0 0
Les incendies de forêt du Texas sont une attaque -délibérée- contre l'approvisionnement alimentaire aux États-Unis. Les incendies de forêt du Texas sont été lancés par des armes énergétiques ditégées. Les incendies de forêt du Texas sont été lancés par des armes énergétiques ditégées. By a moins de deux semaines awant la dete limite pour s'inscrite pour voter dans le Wasconsin. Béfinir la nouvelle application de journal d'Apple "Permet à quiconque près de chez vous connaissez votre non complet et exactement où vous êtes géo-localisé." Michael Moore soutient Trump ion des élections de 2024. Si vous allies -n'importe où dans le montes, vous pourriez obtenir une ordonnance rempile de 40% à 80% de moins qu'ele coûte aux États-Unis aux États-Unis Avôter nom fegat et en faut une sociéd. Cest pourqueu view veys troujeurs votre nom écrit dans toutes les plarfonds. À New York, -élections locales, les immigrants litégaux peuvent voter. Le comité de boxe clymplque - décidé cette année que les hemmes pouvieint es bloquer contre les femmes aux Jeux olymplques Chuck Schumers a pris e mirror chausci completer pour -éliment es répúblicaisent et Maga- pour des returds de réforme. Les commertaires du président Joe filiden sur les maisons du Toxas sont la preuve que les maisons d'une certains couleur sont épargrése des incendies de forêt. Le ministre polonais des Affaires étrangères a décidré que les États-Unis étatient "dysfonctionnes et peur faiteles" cer il n'a pas envoys plus d'aide à l'Utrains. Le poutet et les vaches ont des niveaux élevis d'ateropiènes, ce qui conduit les hommes qui les mangent à chauve, dévéeppent des seins et ne pauvent pas cultiver la masse musculaire. -Lune de mes responsabilités en lant que secrétaire d'État est les actes de contre-insignes adoptés par l'Assembléé législative et signé par le gouverneur Evers. -Les fottschiel détaient à l'origie de la Réserve fédéraix, et la contrellent des contre-insignes adoptés par l'Assembléé législative et signé par le gouverneur Evers.	0 0 0 0 0 0
Le nicondies de forêt du Texas ont été lancés par des armes énergétiques dirigées. La pétition du Texas pour interdre la «pubérisation aérosolisée» est la preuve de Chentralia. La pétition du Texas pour interdre la «pubérisation aérosolisée» est la preuve de Chentralia. Périmie la nouvelle application de journal d'Apple "Permet à quiconque près de chez vous connaissez votre nom complet et exactement où vous êtes géo-localisé." Michael Morce soulent Trume Jone des décisions de 2024. Si vous aillize «n'imports où dans la monde», vous pourriez obtenir une ordonnance remplie de 40% à 80% de moins qu'elle coûte aux États-Unis au	0 0 0 0 0
La pétition du Texas pour interdire la «pulvérisation aérosolisée» est la preuve de Chembrails. Il y a moins de deux semaines avant la date limite pour s'inscrire pour voter dans le Wisconsis. By a moins de deux semaines avant la date limite pour s'inscrire pour voter dans le Wisconsis. Biblier de l'Appendix de la pluma d'Appen *Permet a l'aquionque près de chez vous comaisses votre nom complet et exactement où vous êtes géo-localisé.* Michael Moore soutient Trump lors des élections de 2024. Si vous alliez-n'imports où dans le mondes, vous pourriez obtenir une ordonnance rempile de 40% à 60% de moins qu'elle coûte aux États-Unis aux États-Unis avant de la constité de boxes objets de natie une soicité. Ceré pourqueur vous voyex toujours voter nom écrit dans toutes les platfonds. A tieve York, «élections locales, les immigrants lifejaux peuvent voter». Le comité de boxes objets qu'elle dois de décidé cette année que les hommes pouvaient se bioquer contre les femmes aux Jeux olympiques». Chuck Schumer a pris le micro chauct- comploter pour «billamer les républicains et Maga» pour des retards de réforme. Le commetaires du président Joe Bildens sur les maisons du Texas sont la preuve que les maisons d'une certaine couleur sont épargrées des incendies de forêt. Le ministre poionais des Affaires étrangères a édiciré que les États-Unis étaient "dynfonctionnels et peur flables" cert in n'a pas envoys plus d'aids à l'Uraine. - "2" millions d'illégaux sont entrés aux États-Unis sous aréministration Bildens", montrant que "le" grand remplicacement "ver pas une thécier, évet une réalité. Le poulet et les vaches ont des niveaux élevés d'restrophnes, ce qui conduit les hommes qui les mangent à chauves, développent des seins et ne peuvent pas cultiver la masse musculaire. - Luiu de mes responsabilités en tant que servitaine d'État et ils excles de control-insignes adobjets » Pr. Assembélé réglastève et signé par le gouverneur Evers. - Les Rothschild étaient à l'origine de la Réserve fédéraix, et ils contrôlent dé	0 0 0 0 1 0 0
By a moins de deux semaines avant la date limite pour s'inscrire pour voter dans le Wisconsin. Définir la nouvelle application de journal d'Apple "Permet à quiconque pois de chez vous comaissez votre nom complet et exactement où vous êtes géo-localisé." Michael Moors soulient Trump lors des édections de 2024. Si vous allite: «n'importe où dans le monde», vous pourriez obtenir une ordonnance rempile de 40% à 60% de moins qu'elle coûte aux États-Unis aux États-Unis «Votre nom légal est en fait une société. C'est pourquoi vous veryex toujours votre nom écrit dans toutes les platfonds. À New York, «dections locales, les immigrants litigaux peveret voter». Le comité de boxe olympique» a décidé cette année que les hommes pouvaient es bloquer contre les femmes aux Jeux olympiques». Chuck Schumer a pris le misroc hautou completer pour-diablem et se pépticionien et Maga- pour des retards de réforme. Les commentaires du président Joe Biden sur les maisons du Texas sont la preuve que les maisons d'une certaine couleur sont épargnées des incendies de forêt. Le ministre polonais des Affaires étrangères a décider que les États-Unis étaitent "dystonctionnels et pour liables" er il n'is pas envoyé plus à dida à l'Uturaine. "7.2 millions d'illiques vote mérités aux États-Unis sous tradministration Biden", montrant que le "granter pas une théorie, c'est une réalié. Le poutet le les seches ont des niveaux élevis d'orstropines, ce qui conduit les hommes qui les mangent à chauve, dévelopent des seins et ne pauvent pas cultiver la masse musculaire. -Lune de mes responsabilités en lant que secrétaire d'État est les actes de contre-insignes adoptés par l'Assembléé législative et signé par le gouverneur Evers. -Les fottachiel déstant à l'origine de la Réserve fédéraix, et les contrellent désonais le système financier mondal.	0 0 0 1 0
Définir la nouvelle application de journal d'Apple "Permet à quiconque près de chez vous connaissez votre nom complet et exactement où vous êtes géo-localisé." Michael Moore southent Trump lons des élections de 2024. Se vous allier, "mignor bot dans les mondes, vous pourirez obtenir une ordonnance rempile de 40% à 80% de moins qu'elle coûte aux États-Unis aux États-Unis Votre nom légal est en fait une société. C'est pourquoi vous voyez toujours votre nom écrit dans toutes les platfonds. À tiew York, «féctions locales, les immigrants lifègaux peuvent voter». A tiew York, «féctions locales, les immigrants lifègaux peuvent voter». Chuck Schumer a pris le micro chaud- comploter pour «blâmer les républicains et Maga» pour des retards de réforme. Les commentaires du président Joe Biden sur les maisons du Texas sont la preuve que les maisons d'une certains couleur sont épargnées des incendies de forêt. Les misistre polonais des Affaires étrangiers a décluré que les Estats-Unis étaters d'en platfales" cert in 1 pas envoyé plus d'aide à l'Utrains. 7,2 millions d'ilégaux sont entrés aux États-Unis sous l'administration Biden", montrant que "e" grand remplacement "n'est pas une thécrie, c'est une réalité. Le poulet et les veches ont des niveaux élevés d'estropines, ce qui conduit les hommes qui les mangent à chauve, développent des soins et ne peuvent pas cutiver la mase musculaire. *Lus de mes responsabilités en tant que servisiair d'État et les sectés a cottre	0 0 1 0
Michael Moore soutient Trump Iors des élections de 2024. Si vous allier -n'improte où dans le monde-, vous pourriez obtenir une ordonnance rempile de 40% à 80% de moins qu'elle coûte aux États-Unis aux États-Unis -vôten moi fagat en fait une société. Ceré pourque vious voyex toujours votre nom éarit dans toutes les plainnds. À New York, -élections locales, les immigrants litégaux peuvent voter Le comité de boxe olympique « a électié cette année que les hemmes pouvaient es bioquer contre les femmes aux Jeux olympiques Chuck Schumer a pris e mircor chaud-complete pour-billement es républicains et Magas -pour des retards de réforme. Les commetaires du président de Bilden sur les maisons du Tosas sont la preuve que les maisons d'une certains couleur sont épargrées des incendies de forêt. Le ministre potonais des Affaires étrangères a édiciér que les États-Unis étaient "dysfonctionnels et peur flables" cer il n'a pas envoyé plus d'aids à l'Utraine. "7.2 millions d'illegaux sont entrés aux États-Unis sous réaministration Bilden", montrant que "le" grand remplicement "rest pas une thécier, évet une réalité. Le poulet et les vaches ont des niveaux élevés d'estropines, ce qui conduit les hommes qui les mangent à chauve, dévelopent des seins et ne peuvent pas cutitors la masse musculaire. -Lune de mes responsabilités en lant que secrétaine d'État et les sactes de control-insignes adoptés par l'Assemblée législative et signé par le gouverneur Evers. -Las Rothschild étaient à l'origine de la Riseave tédéraix, et la contrôlent désormais le système financier mondial.	0 1 0
Si vous alliez «n'importe où dans le monde», vous pourriez obtenir une ordonnance rempile de 40% à 80% de moins qu'elle coûte aux États-Unis sux états de la consideration de la considera	1 0
Votre nom légal est en fait une société. C'est pourquoi vous voyez toujours votre nom écrit dans toutes les platfonds. À New York, -élections locales, les immigrants lilégaux peuvent votrer. Chuck Schumer a pris le micro chaud- comploter pour -bitamer les républicains et Maga- pour des retards de réforme. Chuck Schumer a pris le micro chaud- comploter pour -bitamer les républicains et Maga- pour des retards de réforme. Les commentaires du président Jos Biden sur les maisons du Texas sont la preuve que les maisons d'une certains couleur sont épargnées des incendies de forêt. Les commentaires du président Jos Biden sur les maisons du Texas sont la preuve que les maisons d'une certains couleur sont épargnées des incendies de forêt. Les misiter pocinais des Affaires étrangères a dicturé que les Estu-but-lei étaitent périodinctionnes de présidées' cer il ris pas envoyé plus d'aides à l'Utuains. 7,2 millions d'illégaux sont entrés aux États-Unis sous l'administration Biden', montrant que "e" grand remplacement "n'est pas une théorie, c'est une réalité. Le poulet et les vaches ont des niveaux élevés d'estrogènes, ce qui conduit les hommes qui les mangent à chauve, édevésopent des seins et ne peuvent pas cutiver la mase musculaire. -Lunc de mes responsabilités en tat que secrétaire d'êtar et les actes des controis-nisques adobtés par l'Assemblée (égistative et signé par le gouverneur Evers- -Les Rothschild édaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial	0
A New York, -elections locales, les immigrants lifégaux peuvent voter. Le comité de boxe olympique -a décidé cette année que les hommes pouvient se bloquer contre les femmes aux Jeux olympiques. -Chuck Schumer a pris le miror chaute complete pour -blamme les républicains et Magar-pour des retards de réforme. Les commentaires du président Joe Biden sur les maisons du Texas sont la preuve que les maisons d'une certains couleur sont épargnées des incendies de forêt. Le ministre potonais des Affaires étrangères a déclaré que les États-Unis étalent "dysfonctionnels et peur fluides" ar Il n'a pas envoyé plus d'aid à l'Uvraine.	-
Le comité de boxe olympique -a décidé cette année que les hommes pouvaient se bloquer contre les femmes aux Jeux olympiques- «Chuck Schumer a pris le micro chaud- complete pour-blaimer les républicains et Magas- pour des returds de réforme. Les commentaires du président Jos Biden sur les maisons du Texas sont la preuve que les maisons d'une certaine couleur sont épargnées des incendies de forêt. Les misstre poissons des Affaires étrangères a décluré que les États-Unis étaisent "Oyst nonctionneis et pour fablise" car il n'i a pas envoyé plus d'aide à l'Utraine. "7,2 millions d'illégaux sont entrés aux États-Unis sous l'administration Biden", montrant que "le" grand remplacement "rest pas une théorie, c'est une réalité. Le poulet et les vaches ont des niveaux élevés d'estrogènes, ce qui conduit les hommes qui les mangent à chauve, développent des seins et ne peuvent pas cultiver la masse musculaire. -L'une de mes responsabilités en tant que secrétaire d'État et les actes de control-ingiques adoptés per l'Assemblée (signistive et signé par le gouverneur Evers- -Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais is système financier mondial.	
Chuck Schumer a pris la micro chaud- comploter pour -bitamer les républicains et Maga- pour des retards de réforme. Les commentaires du président Jos Biden sur les maisons du Texas sont la preuve que les maisons d'une certains couleur sont épargnées des incendies de forêt. Les misiter pocinais des Affaires étragnées à décluré que les Estu-brie étaitent pour plante de président cert n'un pas envoyé plus d'aids à l'Utraine. 7,2 millions d'illégaux sont entrés aux États-Unis sous l'administration Biden', montrant que "e" grand remplacement "n'est pas une thécrie, c'est une réalité. Le poulet et les vaches ont des niveaux élevés d'estrogènes, ce qui conduit les hommes qui les mangent à chauve, développent des seins et ne peuvent pas cultiver la masse musculaire. -Lunc de mes responsabilités en tant que sercitaire d'État et les actes des control-nerigines adobtés per l'Assembéle (signistive et signé par le gouverneur Evers- -Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial.	0
Les commentaires du président Joe Biden sur les maisons du Texas sont la preuve que les maisons d'une certaine couleur sont épargnées des incendies de forêt. Le ministre potonais des Affaires étrangènes a déciaré que les Étate-Unis étatient "dysthoctionnels et pour liables" er et in 2 pas envoyé plus didà à l'Uturaine. "72 millions d'illiques cont entrés aux États-Unis sous pradimisations lidies", montant que le "grander pas une théoric, ets en residies. Le poutet le les seches ont des niveaux étevis d'extrogimes, ce qui conduit les hommes qui les mangent à chauve, développent des seins et ne peuvent pas cultiver la masse musculaire. -L'une de mes responsabilités en tant que socrétaire d'État est les actes de contre-insignes adoptés par l'Assemblée législative et signé par le gouverneur Evers. -Les Rotschild étatent à l'origine de la Héserve fédéraix, et les controllent désonmais le système financier mondai	0
Le ministre potonais des Affaires étrangères a déclaré que les États-Unis étaient "dysfonctionnels et peu flables" cer il n'a pas envoyé plus d'aide à l'Ukraine. "7.2 millions d'illégaux sont entrés aux États-Unis sous l'administration Bident", montrant que "le' grand remplacement "riest pas une thécins, c'est une réalité. Le poulet et les vaches ont des niveaux élevés d'œstrogènes, ce qui conduit les hommes qui les mangent à chauve, développent des seins et ne peuvent pas cultiver la masse musculaire. -L'une de mes responsabilités en tant que secrétaire d'État est les actes de contre-insignes adoptés par l'Assemblée législative et signé par le gouverneur Evers. -Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial.	0
7.2 millions d'illégaux sont entrés aux États-Unis sous l'administration Biden', montrant que "e" grand remplacement "n'est pas uns théoris, c'est une réalité. Le poulet et les vaches ont des niveaux élevés d'estrogènes, ce qui conduit les hommes qui les mangent à chauve, développent des seins et ne peuvent pas cultiver la masse musculaire. -L'une de mes responsabilités en tant que secrétaire d'êtar et les actes de control-insignes adobjès per l'Assemblée (eigislative et signé par le gouverneur Evers- -Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial	0
Le poulet et les vaches ont des niveaux élevés d'œstrogènes, ce qui conduit les hommes qui les mangent à chauve, développent des seins et ne peuvent pas cultiver la masse musculaire. L'une de mes responsabilités en tant que secrétaire d'État est les actes de contre-insignes adoptés par l'Assemblée législative et signé par le gouverneur Evers.» Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial.»	0
L'une de mes responsabilités en tant que secrétaire d'État est les actes de contre-insignes adoptés par l'Assemblée législative et signé par le gouverneur Evers.» -Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial.»	0
-Les Rothschild étaient à l'origine de la Réserve fédérale, et ils contrôlent désormais le système financier mondial.»	0
	0
	0
Cinquante pour cent des votes pour Joe Biden lors des élections primaires présidentielles du Michigan étaient envoyées par la poste, non vérifiées, pas de signature, pas de pièce d'identité.	0
Ce n'est pas l'ancien président Donald Trump qui a promu le vaccin Covid-19, mais un «sosie».	0
Le gouvernement a fait plus pour arrêter la distribution de l'ivermectine et de l'hydroxychloroquine que pour arrêter la distribution du fentanyl.	0
La Loi sur les puces et les sciences de 2022 «a attiré 640 milliards de dollars d'investissements des entreprises privées».	0
La photo montre l'incendie de Smokehouse Creek au Texas.	0
"L'étude révèle que la fausse viande de Bill Gates provoque des" cancers turbo "chez l'homme."	0
Donald Trump a appelé sa femme "Mercedes" au lieu de Melania.	0
Les poussées solaires ont provoqué une panne de téléphone cellulaire AT&T.	0
Taylor Swift a déclaré qu'elle "quitterait les États-Unis si Donald Trump devient président en 2024."	0
«La Caroline du Nord a la plus longue période de vote du pays et nous avons la plupart des façons de voter.»	- 1

Part of testing dataset

testing

Title	Label
President Biden confirm(ed) everyone will receive their \$1k gas checks this week!!	0
When Joe Biden "walked into this administration 20 million people were on unemployment insurance benefits."	0
Image shows Paul Pelosi, bruised, in a booking mugshot.	0
"Not a single person in the crowd on January 6 was found to be carrying a firearm. Not one."	0
There are more females on Facebook than alive in the world.	0
"U.S. military at the White House arresting Congress."	0
"Military take over on May 11 confirmed!"	0
Americans aren't required to show IDs to vote.	0
"Donald Trump authorized up to 20,000 National Guard troops to protect the Capitol" before Jan. 6, 2021, but was "rejected" by Nancy Pelosi and Chuck Schumer.	0
"Bennie Thompson actively cheer-led riots in the '90s."	0
"A quarter of the entire acreage in the country that is under hemp production is here in North Carolina."	0
"U.S. military arrests Michael Sussmann."	0
The official pride flag was altered to include Ukrainian colors.	0
A "public health warning" was recently issued for fluoride toothpaste.	0
Gavin Newsom reportedly intervened at the request of Nancy Pelosi and directly ordered the California Highway Patrol to drop all charges* against Paul Pelosi for his DUI arrest.	0
Joe Biden approved a "new card" that "gives free health insurance to Americans" who are 25 and older.	0
Nearly 60% of all student loan debt is held by the rich and upper-middle class," so forgiveness would give the wealthy a "financial windfall" but not really help low-income people.	1
"Bennie Thompson objected to the 2004 Presidential election."	1
The Jan. 6, 2021, attack on the U.S. Capitol "was a dust-up."	0
Baby boomers didn't have autism, seizures, allergies and other ailments when they were kids.	0
Ray Liotta died because of the COVID-19 vaccine.	0
Says Barack Obama announced Joe Biden's death.	0
"There are fewer lowans working today than when Gov. Reynolds took office."	1
Joe Biden resigned and "Trump is the new president."	0
On building an NFL stadium in Virginia.	0
White supremacists are going to be "shooting up all Walmarts and will kill Blacks and Mexicans" in San Bernardino, California.	0
"USDA is predicting egg prices will be \$12 a dozen by fall 2022."	0
"Public schools are now as segregated by race and class as they were in the 1960s."	1

References:

- 1. https://www.politifact.com
- 2. https://twitter.com
- 3. https://nytimes.com
- 4. https://newsapi.org
- 5. https://mehtaplustutoring-mlbootcamp20.github.io/Real_vs_Fake_News/
- 6. https://www.sciencedirect.com/science/article/pii/S2665917424000047
- 7. https://www.scitepress.org/PublishedPapers/2021/105620/105620.pdf
- 8. https://github.com/Cartus/Automated-Fact-Checking-Resources
- 9. https://github.com/ejupialked/fake-news-detection
- 10. https://www.sciencedirect.com/science/article/pii/S2405959521001375
- 11. https://arxiv.org/pdf/1806.00749.pdf
- 12. https://towardsdatascience.com/latent-dirichlet-allocation-lda-9d1cd064ffa2
- 13. https://medium.com/@corymaklin/latent-dirichlet-allocation-dfcea0b1fddc

Appendix:

CNN:

```
import numpy as np
      from sklearn.model_selection import cross_val_predict, cross_val_score, KFold from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score, confusion_matrix
      from tensorflow.keras.models import Sequential from tensorflow.keras.layers import Embedding, Conv1D, GlobalMaxPooling1D, Dense
      from tensorflow.keras.preprocessing.text import Tokenizer from tensorflow.keras.preprocessing.sequence import pad_sequences
      import seaborn as sns
      # Load training dataset from CSV file
train_data = pd.read_csv('large.csv')
      test_data = pd.read_csv('testing.csv')
      combined_data = pd.concat([train_data['Title'], test_data['Title']], ignore_index=True)
      tokenizer.fit_on_texts(combined_data)
       X_train_sequences = tokenizer.texts_to_sequences(train_data['Title'])
      X_test_sequences = tokenizer.texts_to_sequences(test_data['Title'])
      # Pad sequences to ensure uniform length
max_sequence_length = max([len(seq) for seq in X_train_sequences + X_test_sequences])
      X_train_padded = pad_sequences(X_train_sequences, maxlen=max_sequence_length)
X_test_padded = pad_sequences(X_test_sequences, maxlen=max_sequence_length)
      model.add(Embedding(input_dim=len(tokenizer.word_index) + 1, output_dim=100, input_shape=(max_sequence_length,)))
model.add(Conv1D(128, 5, activation='relu'))
      model.add(GlobalMaxPooling1D())
      model.add(Dense(1, activation='sigmoid'))
     # Perform cross-validation on training data
kf = KFold(n_splits=5, shuffle=True, random_state=42)
      precision_scores = []
recall_scores = []
     f1_scores = []
auc_scores = []
      conf_matrices = []
      for train_index, val_index in kf.split(X_train_padded):
            X_train, X_val = X_train_padded[train_index], X_train_padded[val_index]
y_train, y_val = train_data['Label'].iloc[train_index], train_data['Label'].iloc[val_index]
            # Predict Labels for validation data
y_pred = (model.predict(X_val) > 0.5).astype(int)
             accuracy_scores.append(accuracy_score(y_val, y_pred))
            precision_scores.append(precision_score(y_val, y_pred))
recall_scores.append(recall_score(y_val, y_pred))
            f1_scores.append(f1_score(y_val, y_pred))
auc_scores.append(roc_auc_score(y_val, y_pred))
             conf_matrices.append(confusion_matrix(y_val, y_pred))
71 print("Average Accuracy:", np.mean(accuracy_scores))
72 print("Average Precision:", np.mean(precision_scores))
73 print("Average Recall:", np.mean(recall_scores))
74 print("Average FS Score:", np.mean(fiscores))
75 print("Average AUROC Score:", np.mean(auc_scores))
      history = model.fit(X_train_padded, train_data['Label'], epochs=5, batch_size=64, verbose=0)
      y_test_pred = (model.predict(X_test_padded) > 0.5).astype(int)
      print(test conf matrix)
      plt.figure(figsize=(8, 6))
      sns.heatmap(test_conf_matrix, annot=True, cmap='Blues', fmt='g')
      plt.xlabel('Predicted labels')
plt.ylabel('True labels')
      plt.show()
```

```
import pandas as pd
   from sklearn.feature_extraction.text import TfidfVectorizer
 3 from sklearn.svm import SVC
    from sklearn.metrics import confusion_matrix, roc_curve, roc_auc_score
    import matplotlib.pyplot as plt
8 from sklearn.model_selection import cross_val_predict, cross_val_score
11 train_data = pd.read_csv('large.csv')
12 test_data = pd.read_csv('testing.csv')
14 X_train = train_data['Title']
15 y_train = train_data['Label']
17 X_test = test_data['Title']
18  y_test = test_data['Label']
21 svm_classifier = Pipeline([
         ('svm', SVC(kernel='linear', probability=True)) # Support Vector Machine classifier
   y_pred_cv = cross_val_predict(svm_classifier, X_train, y_train, cv=5, method='predict_proba')[:, 1]
29 # Calculate evaluation metrics using cross-validation
30 accuracy_cv = cross_val_score(svm_classifier, X_train, y_train, cv=5, scoring='accuracy').mean()
31 precision_cv = cross_val_score(svm_classifier, X_train, y_train, cv=5, scoring='precision').mean()
    recall_cv = cross_val_score(svm_classifier, X_train, y_train, cv=5, scoring='recall').mean()
33 f1_cv = cross_val_score(svm_classifier, X_train, y_train, cv=5, scoring='f1').mean()
34 roc_auc_cv = cross_val_score(svm_classifier, X_train, y_train, cv=5, scoring='roc_auc').mean()
36 print("Cross-Validation Metrics:")
37 print("Accuracy:", accuracy_cv)
38 print("Precision:", precision_cv)
39 print("Recall:", recall_cv)
40 print("F1 Score:", f1_cv)
   print('ROU-AUC:', roc_auc_cv)
43 # Fit the classifier on the full training data
svm_classifier.fit(X_train, y_train)
47  y_pred_probs = svm_classifier.predict_proba(X_test)[:, 1]
49 fpr, tpr, thresholds = roc_curve(y_test, y_pred_probs)
50 auc_score = roc_auc_score(y_test, y_pred_probs)
52 conf_matrix = confusion_matrix(y_test, y_pred_probs.round())
53 print(conf_matrix)
56 plt.figure(figsize=(8, 6))
57 sns.heatmap(conf_matrix, annot=True, cmap='Blues', fmt='g')
58 plt.xlabel('Predicted labels')
59 plt.ylabel('True labels')
60 plt.title('SVM Confusion Matrix Large')
61 plt.show()
```

```
1 import pandas as pd
 2 from sklearn.feature_extraction.text import CountVectorizer
 3 from sklearn.decomposition import LatentDirichletAllocation
 4 from sklearn.metrics import accuracy_score, classification_report
 6 train_data = pd.read_csv('training_bias_french.csv')
   test_data = pd.read_csv('testing_french.csv')
 9 X_train = train_data['Title']
10 y_train = train_data['Label']
12 X_test = test_data['Title']
13 y_test = test_data['Label']
15 # Preprocess the text data
16 vectorizer = CountVectorizer()
17  X_train_counts = vectorizer.fit_transform(X_train)
18  X_test_counts = vectorizer.transform(X_test)
20 # Train the LDA model
21  lda = LatentDirichletAllocation(n_components=2, random_state=42)
22  X_train_lda = lda.fit_transform(X_train_counts)
23  X_test_lda = lda.transform(X_test_counts)
25 # Evaluate the model
26 # Predict the labels for the testing data
27 y_pred = [0 if topic[0] > topic[1] else 1 for topic in X_test_lda]
29 # Compute accuracy
30 accuracy = accuracy_score(y_test, y_pred)
31 print("Accuracy:", accuracy)
33 # Generate classification report
34 print("Classification Report:")
35 print(classification_report(y_test, y_pred))
```